Previsão de inadimplência de crédito

Este estudo compara classificadores de inadimplência de cartão de crédito e investiga o efeito de arquitetura, ativação, regularização, balanceamento e preparação dos dados em redes neurais. Foram executados 140 ajustes: 28 configurações em cinco sementes, usando os 30.000 registros oficiais do dataset Default of Credit Card Clients.

Entre as redes PyTorch avaliadas, Ativação tanh obteve a maior AP média de validação (0,543 ± 0,011). O XGBoost alcançou 0,543 ± 0,009 e permaneceu como padrão entre os três modelos integrados à aplicação. As diferenças pequenas entre os melhores candidatos não demonstram superioridade geral de um algoritmo.

Entrega: aplicação integrada, resultados brutos, relatório completo, síntese e apresentação.

1. Problema e perguntas de pesquisa

O objetivo é estimar se um cliente deixará de pagar no mês seguinte a partir do limite, perfil e histórico de seis meses. Como cerca de 22,1% dos registros pertencem à classe inadimplente, acurácia isolada é insuficiente.

P1: uma MLP supera kNN e classificadores lineares? P2: como largura, profundidade e ativação afetam o desempenho e a convergência? P3: quais efeitos são observados com L2, dropout, batch normalization e balanceamento? P4: como normalização, one-hot e inicialização mudam os resultados?

2. Dados, limpeza e partições

Partição	Registros	Taxa inadimplente
fit	16564	0,221
stop	2552	0,221
calibration	2549	0,221
validation	3831	0,221
Referência já consultada	4504	0,221

Referência fixa: 4.504 registros já consultados. Ajuste, parada, calibração e seleção usam partições distintas.

3. Protocolo e controle de vazamento

Cinco sementes: 7, 21, 42, 84 e 123. As mesmas partições são usadas por todos os candidatos em cada repetição.

140 ajustes: 7 baselines, 18 redes e 3 ablações de atributos sensíveis por semente. Máximo de 80 épocas nas redes, com parada antecipada.

Modelo: AP média de validação. Calibrador: Brier médio de validação. Limiar: F1 na validação. A referência já consultada não participa dessas escolhas.

5. P1 — comparação de modelos

Modelo	AP média ± DP	ROC média	F1 médio	Recall médio
Regressão logística	0,495 ± 0,012	0,724	0,511	0,510
SVM linear + sigmoide	0,492 ± 0,012	0,720	0,511	0,497
kNN L1 (k=25)	0,483 ± 0,010	0,739	0,495	0,520
kNN L2 (k=25)	0,491 ± 0,010	0,742	0,507	0,537
Random forest	0,543 ± 0,016	0,773	0,541	0,562
XGBoost	0,543 ± 0,009	0,774	0,544	0,544
MLP scikit-learn	0,538 ± 0,011	0,768	0,536	0,572
MLP 64/32, ReLU	0,534 ± 0,013	0,769	0,535	0,557
Ativação tanh	0,543 ± 0,011	0,770	0,535	0,563

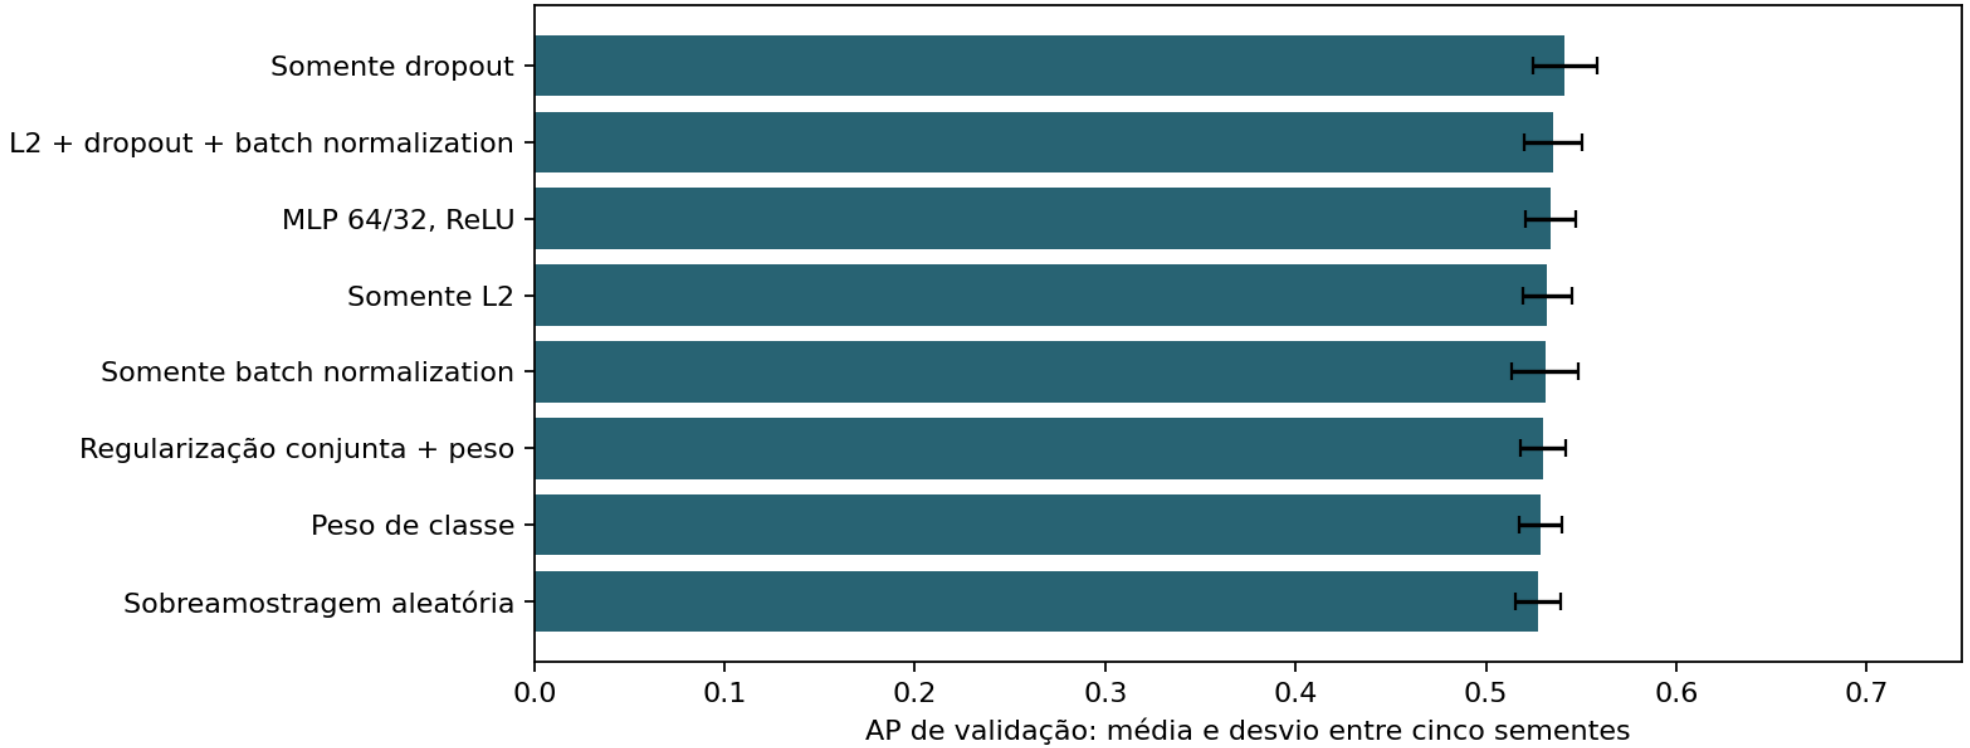
Redes e árvores ficaram próximas. O XGBoost liderou os três modelos disponíveis na aplicação.

6. P2 — arquitetura, ativação e convergência

Configuração	AP média ± DP	Melhor época média	Gap BCE médio
MLP 64/32, ReLU	0,534 ± 0,013	25,6	0,015
Uma camada: 32	0,524 ± 0,013	63,2	0,011
Uma camada: 128	0,527 ± 0,012	33,4	0,013
Três camadas: 128/64/32	0,532 ± 0,014	14,0	0,015
Ativação tanh	0,543 ± 0,011	43,2	0,011
Ativação sigmoide	0,525 ± 0,021	67,4	0,005

Mais camadas não garantiram melhor AP. Tanh liderou as redes avaliadas.

7. P3 — regularização e balanceamento



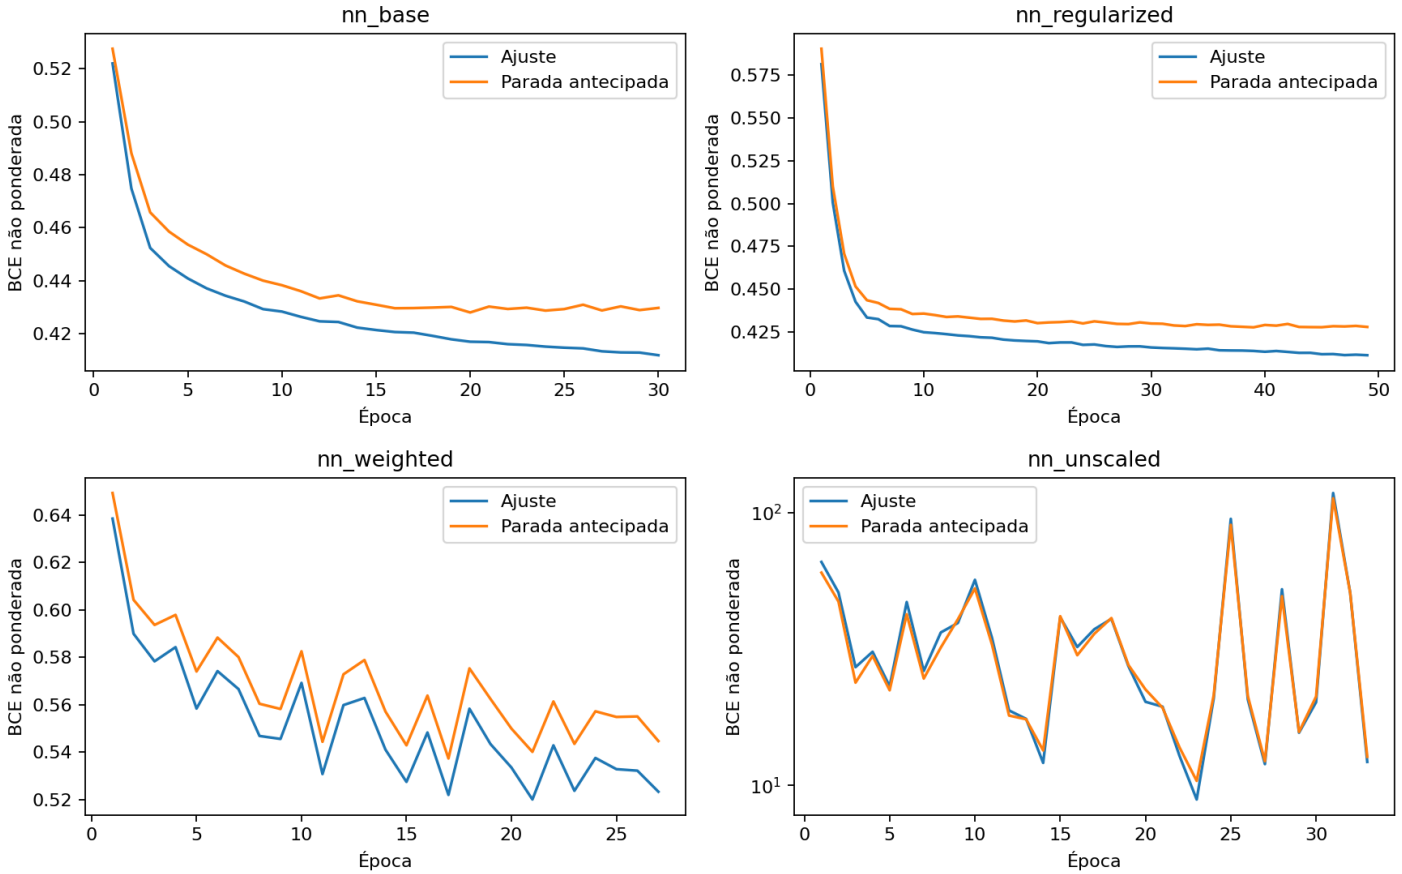
L2 é implementado por weight_decay=0,001 no Adam; dropout usa probabilidade 0,30; batch normalization é aplicada após as camadas lineares ocultas. Há ablações individuais e uma combinação das três técnicas. O peso positivo na BCE é a razão entre negativos e positivos de fit. A sobreamostragem aleatória iguala as classes usando apenas exemplos de fit.

8. P4 — pré-processamento e inicialização

Configuração	AP média ± DP	ROC média	Melhor época média
MLP 64/32, ReLU	0,534 ± 0,013	0,769	25,6
Sem normalização	0,281 ± 0,020	0,618	21,0
Sem one-hot	0,533 ± 0,015	0,768	29,8
Sem normalização e sem one-hot	0,288 ± 0,015	0,628	18,6
Inicialização Xavier	0,532 ± 0,015	0,764	23,0
Inicialização Kaiming	0,529 ± 0,008	0,765	24,0

A normalização teve o maior efeito nesse desenho; não houve ganho uniforme com Xavier ou Kaiming.

9. Curvas de aprendizagem



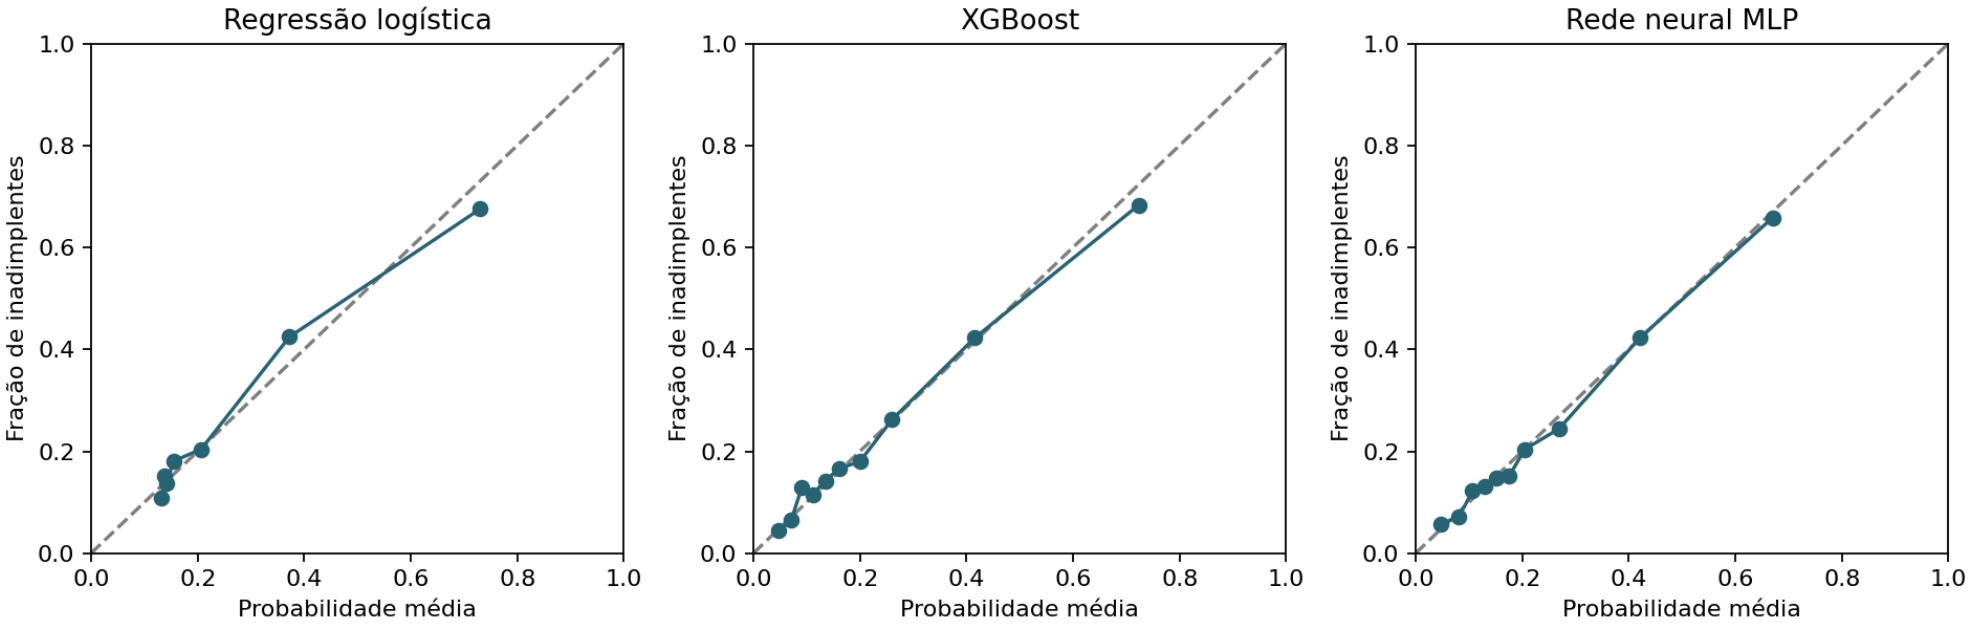
A figura mostra quatro configurações na semente 42: controle, regularização conjunta, peso de classe e ausência de normalização. As perdas são BCE não ponderada calculada em modo de avaliação, de modo que dropout fica desligado e batch normalization usa as estatísticas aprendidas. O objetivo usado durante o gradiente pode ser ponderado, mas a curva relatada usa a mesma definição de perda.

10. Calibração de probabilidades

Modelo	Método	Brier médio ± DP	Log loss médio	ECE médio
Regressão logística	none	0,146 ± 0,002	0,467	0,045
Regressão logística	sigmoid	0,147 ± 0,001	0,467	0,049
Regressão logística	isotonic (escolhida)	0,144 ± 0,002	0,481	0,019
XGBoost	none (escolhida)	0,136 ± 0,001	0,434	0,014
XGBoost	sigmoid	0,137 ± 0,001	0,434	0,016
XGBoost	isotonic	0,138 ± 0,002	0,448	0,023
Rede neural MLP	none	0,138 ± 0,002	0,440	0,019
Rede neural MLP	sigmoid (escolhida)	0,138 ± 0,002	0,438	0,015
Rede neural MLP	isotonic	0,139 ± 0,002	0,450	0,017

A escolha usa Brier médio de validação. Calibração não melhora necessariamente todas as métricas.

11. Confiabilidade na referência já consultada



Os pontos mostram a fração observada de inadimplentes contra a probabilidade média de cada grupo, para os modelos finais da semente 42. A diagonal representa coincidência entre as duas medidas. Oscilações, sobretudo em grupos pequenos e extremos, não devem ser interpretadas como estabilidade fora desta base.

12. Avaliação complementar de referência

Modelo	AP	IC 95% AP	ROC	F1	Recall
Regressão logística	0,468	0,434–0,502	0,712	0,492	0,452
XGBoost	0,529	0,496–0,566	0,768	0,525	0,512
Rede neural MLP	0,517	0,483–0,552	0,756	0,511	0,578
kNN L1	0,479	0,444–0,513	0,737	0,486	0,480
kNN L2	0,475	0,441–0,508	0,730	0,490	0,490
SVM linear	0,485	0,451–0,522	0,708	0,481	0,425
Random forest	0,534	0,500–0,569	0,764	0,526	0,555
MLP PyTorch: tanh	0,524	0,490–0,558	0,758	0,521	0,588

Avaliação complementar, sem alegação de teste inédito. Intervalos condicionais ao modelo ajustado.

13. Atributos sensíveis e diferenças por grupo

Modelo	AP completa	AP sem sensíveis	Diferença
Regressão logística	0,495	0,494	-0,001
XGBoost	0,543	0,540	-0,003
Rede neural MLP	0,538	0,519	-0,019

Excluir atributos sensíveis não comprova ausência de discriminação.

14. Cenários de custo e limiares

Custo FN / FP	Limiar validação	FN referência	FP referência	Custo / mil
1 / 1	0,396	572	261	184,9
2 / 1	0,299	486	434	312,2
5 / 1	0,192	327	981	580,8
10 / 1	0,083	55	2610	701,6

Resultados do protocolo de cinco sementes; os detalhes e as limitações estão no relatório.

16. Limitações e conclusões

P1: as redes testadas superaram kNN e classificadores lineares pela AP média observada; as melhores redes e os modelos de árvores ficaram próximos. P2: tanh teve o melhor resultado entre as ativações estudadas; profundidade maior não assegurou melhora. P3: dropout ajudou nesse desenho, enquanto a combinação de técnicas e o balanceamento não trouxeram ganhos uniformes. P4: a normalização teve efeito muito maior do que retirar one-hot ou trocar a inicialização nas condições testadas.

Calibrar não é necessariamente melhorar todas as métricas. Os métodos finais foram escolhidos pelo Brier de validação, preservando a opção de não ajustar o XGBoost. A escolha por Brier pode divergir de log loss e de métricas de ordenação.

Os cinco resultados por configuração não são cinco amostras independentes da população. A busca é limitada a uma grade pequena e a uma taxa de aprendizado. Não houve busca exaustiva, teste externo recente ou validação temporal. O conjunto de referência já tinha sido consultado e seus intervalos são condicionais aos modelos.

Referências

YEH, I-Cheng; LIEN, Che-hui. Default of Credit Card Clients. UCI Machine Learning Repository, 2009. DOI: 10.24432/C55S3H. Licença CC BY 4.0.

YEH, I-Cheng; LIEN, Che-hui. The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. Expert Systems with Applications, v. 36, n. 2, 2009.

CHEN, Tianqi; GUESTRIN, Carlos. XGBoost: A Scalable Tree Boosting System. KDD, 2016. DOI: 10.1145/2939672.2939785.