Previsão de Inadimplência de Crédito com Redes Neurais

Proposta de pesquisa: problema, perguntas, dataset e modelos

Disciplina: Inteligência Artificial | Outubro de 2026

Integrantes: Athos Andre, Lucas Brasileiro, Guilherme Uchoa, Matheus Albuquerque e Dhigor Padilha

1. Problema de pesquisa

Instituições financeiras concedem crédito sem saber, de antemão, se o cliente conseguirá pagar. Quando isso não acontece, ocorre a inadimplência, que gera prejuízo e influencia a definição de limites e de políticas de cobrança. Prever esse risco com antecedência é, portanto, um problema de decisão com valor prático direto.

O problema de pesquisa deste trabalho é: **como prever, a partir do histórico de um cliente de cartão de crédito, se ele deixará de pagar a fatura no mês seguinte, e quais modelos de aprendizado de máquina fazem isso melhor?**

O problema atende às três condições que justificam o uso de aprendizado de máquina (Abu-Mostafa et al., 2012): existe um padrão, pois atrasos e faturas passadas indicam risco; não é possível construir uma equação matemática exata do comportamento de pagamento; e existem dados históricos disponíveis. Além disso, o estudo que originou o dataset comparou seis técnicas de mineração de dados e concluiu que a rede neural foi a única capaz de estimar com precisão a probabilidade real de inadimplência (Yeh e Lien, 2009). Isso motiva investigar com mais detalhe como arquitetura, regularização e pré-processamento influenciam o resultado.

2. Perguntas de pesquisa

Definimos quatro perguntas, que organizam os experimentos e as comparações entre os modelos.

	Pergunta	Como será respondida	Métricas
P1	Um MLP supera o kNN e o classificador linear na previsão de inadimplência?	Treinar os três tipos de modelo com o mesmo protocolo e comparar no conjunto de teste.	Recall, F1, AUC-ROC
P2	Como o número de camadas e de neurônios e a função de ativação (sigmoid, tanh, ReLU) afetam o desempenho e o overfitting?	Variar a arquitetura e a ativação e comparar as curvas de treino e de validação por época.	Diferença entre treino e validação, AUC-ROC
P3	Regularização (L2, dropout, batch normalization) e balanceamento de classes melhoram a detecção de inadimplentes?	Adicionar cada técnica separadamente e em combinação; testar pesos por classe e reamostragem apenas no treino.	Recall da classe inadimplente, F1
P4	Pré-processamento (normalização, codificação das categorias) e inicialização dos pesos mudam a convergência e o resultado?	Treinar com e sem normalização e com diferentes inicializações dos pesos.	Perda por época, AUC-ROC

3. Dataset

Usaremos o **Default of Credit Card Clients**, disponível no UCI Machine Learning Repository e criado por I-Cheng Yeh e Che-hui Lien (2009). Ele reúne **30.000 clientes** de um banco de Taiwan, com dados de abril a setembro de 2005, e **23 variáveis** explicativas, sem valores faltantes segundo a documentação. A variável-alvo é binária: o cliente foi inadimplente no mês seguinte (1) ou não (0). O dataset é distribuído sob a licença Creative Commons Attribution 4.0 (CC BY 4.0), que permite o uso com a devida citação.

Grupo de variáveis	Descrição	Quantidade
Limite de crédito	Valor do crédito concedido, individual e familiar (X1)	1
Perfil do cliente	Sexo, escolaridade, estado civil e idade (X2 a X5)	4
Histórico de pagamento	Situação do pagamento de abril a setembro de 2005 (X6 a X11)	6
Valores das faturas	Valor da fatura em cada um dos seis meses (X12 a X17)	6
Valores pagos	Valor pago em cada um dos seis meses (X18 a X23)	6

Desbalanceamento. Dos 30.000 clientes, 6.636 (cerca de 22,1%) são inadimplentes e 23.364 não são. Um modelo que classifique todos como bons pagadores já alcança aproximadamente 77,9% de acurácia sem aprender nada. Por isso a acurácia será apenas uma referência, e a avaliação usará recall, precisão, F1, AUC-ROC e matriz de confusão.

Cuidados com os dados. As variáveis categóricas já vêm codificadas como números; como nem sempre há uma ordem entre as categorias, também testaremos a codificação one-hot. Verificaremos categorias com valores inesperados antes do treino. Propomos dividir os dados de forma estratificada em treino, validação e teste (inicialmente 70%, 15% e 15%), mantendo a proporção de inadimplentes em cada parte e usando o teste apenas no final.

4. Possíveis modelos e justificativa

Aumentaremos a complexidade dos modelos de forma gradual, o que permite observar a relação entre capacidade, viés e variância vista em aula.

Modelo	Papel no estudo	Justificativa	Hiperparâmetros principais
kNN (distâncias L1 e L2)	Baseline sem aprendizado	Compara clientes por distância; mostra o limite dessa abordagem e é sensível à escala dos dados.	k, tipo de distância
Linear (softmax e SVM loss)	Baseline linear	Cada variável recebe um peso aprendido; permite comparar as perdas cross-entropy e hinge.	Taxa de aprendizado, força da regularização
MLP com 1 camada escondida	Primeira não linearidade	Capta combinações entre variáveis (por exemplo, limite alto com atrasos recentes) que o modelo linear não capta.	Neurônios, ativação, taxa de aprendizado
MLP profundo com L2, dropout e batch normalization	Modelo de maior capacidade	Mais flexível; as regularizações controlam o overfitting e mostram o equilíbrio entre viés e variância.	Camadas, neurônios, taxa de dropout, força do L2
Random forest (referência opcional)	Referência externa	Métodos baseados em árvores costumam ser competitivos em dados tabulares; evita comparar apenas redes entre si.	Número de árvores, profundidade

Com pouca capacidade o modelo sofre underfitting; perto do ponto ótimo ele generaliza melhor; com excesso de capacidade, sofre overfitting. Não incluímos redes convolucionais porque são voltadas a imagens e os dados aqui são tabulares. Também não assumimos que a rede neural vencerá: os experimentos é que responderão à P1.

5. Como vamos responder

- **Preparação:** codificar as categorias e normalizar as variáveis numéricas, calculando a média e o desvio apenas com o conjunto de treino para evitar vazamento de dados.
- **Ajuste:** escolher os hiperparâmetros com o conjunto de validação ou com validação cruzada K-fold sobre o treino.
- **Avaliação:** comparar os modelos no conjunto de teste com recall, precisão, F1, AUC-ROC e matriz de confusão.
- **Robustez:** repetir os experimentos com sementes diferentes e reportar a média e o desvio.
- **Diagnóstico:** acompanhar as curvas de treino e de validação por época para identificar underfitting e overfitting.

6. Limitações e considerações éticas

Os dados são de 2005 e de um único banco de Taiwan, de modo que os resultados não se generalizam automaticamente para outros países ou épocas. O dataset inclui sexo, idade e estado civil; por isso analisaremos o desempenho por grupo e discutiremos o risco de viés e de discriminação. Este é um estudo acadêmico e seus resultados não devem ser usados para decidir crédito real sem validação adicional.

Referências

ABU-MOSTAFA, Y. S.; MAGDON-ISMAIL, M.; LIN, H.-T. *Learning From Data*. AMLBook, 2012.

IOFFE, S.; SZEGEDY, C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. In: *International Conference on Machine Learning (ICML)*, 2015.

SRIVASTAVA, N. et al. Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learning Research*, v. 15, p. 1929-1958, 2014.

YEH, I.-C.; LIEN, C.-H. The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. *Expert Systems with Applications*, v. 36, n. 2, p. 2473-2480, 2009.

YEH, I. *Default of Credit Card Clients* [Dataset]. UCI Machine Learning Repository, 2009. https://doi.org/10.24432/C55S3H.

ZANCHETTIN, C. *Revisão ML + NN*. Material de aula, Centro de Informática, UFPE.