Proposta de pesquisa · Inteligência Artificial

Previsão de Inadimplência de Crédito com Redes Neurais

Comparando kNN, classificador linear e MLP no dataset Default of Credit Card Clients

Athos Andre, Lucas Brasileiro, Guilherme Uchoa, Matheus Albuquerque, Dhigor Padilha e Alberto Albuquerque

Objetivo da apresentação

Apresentar nossa proposta de pesquisa: comparar modelos de aprendizado de máquina na previsão de inadimplência e justificar as escolhas de dataset e de modelos.

Problema

Perguntas

Dataset

Modelos e método

Problema de pesquisa

Como prever, a partir do histórico do cliente, quem deixará de pagar a fatura do cartão no mês seguinte?

Existe um padrão
Atrasos e faturas passadas indicam risco.

Sem equação exata
Não há fórmula que descreva o comportamento.

Há dados
Registros históricos de clientes reais.

Perguntas de pesquisa

P1

Um MLP supera o kNN e o classificador linear na previsão de inadimplência?

P2

Como arquitetura e função de ativação afetam o desempenho e o overfitting?

P3

Regularização e balanceamento de classes melhoram a detecção de inadimplentes?

P4

Pré-processamento e inicialização dos pesos mudam a convergência e o resultado?

Dataset: Default of Credit Card Clients

30.000

clientes de um banco de Taiwan

23

variáveis: limite, perfil, atrasos, faturas e pagamentos

22,1%

inadimplentes no mês seguinte

Classificar todos como adimplentes já dá 77,9% de acurácia, então avaliaremos com recall, F1 e AUC-ROC.

Fonte: UCI Machine Learning Repository, Yeh e Lien (2009), CC BY 4.0

Modelos e justificativa

Modelo	Papel	Justificativa
kNN (distâncias L1 e L2)	Baseline sem aprendizado	Mostra o limite de comparar pontos e a sensibilidade à escala
Linear (softmax e SVM loss)	Baseline linear	Pesos aprendidos; compara cross-entropy e hinge loss
MLP com 1 camada escondida	Primeira não linearidade	Capta interações entre variáveis que o modelo linear não capta
MLP profundo com L2, dropout e batch norm	Modelo mais complexo	Mostra o equilíbrio entre viés e variância

Como vamos responder

1 Preparar

Normalizar, codificar categorias e separar treino, validação e teste com estratificação.

2 Treinar

Ajustar hiperparâmetros com validação ou K-fold CV.

3 Avaliar

Recall, F1, AUC-ROC e matriz de confusão.

4 Comparar

Curvas de treino e validação, várias sementes e random forest como referência.

Sexo, idade e estado civil estão nos dados, então também discutiremos viés e justiça do modelo.