Previsão de Inadimplência de Crédito com Redes Neurais

Relatório de resultados e comparação com modelos de referência

Estudo executado com dados oficiais da UCI · cinco sementes · código e resultados reproduzíveis

Autores informados no repositório: Athos Andre, Lucas Brasileiro, Guilherme Uchoa, Matheus Albuquerque e Dhigor Padilha.

Base: Taiwan, abril a setembro de 2005. O conjunto de referência já foi consultado em etapa anterior.

Resumo

Este estudo compara classificadores de inadimplência de cartão de crédito e investiga o efeito de arquitetura, ativação, regularização, balanceamento e preparação dos dados em redes neurais. Foram executados 140 ajustes: 28 configurações em cinco sementes, usando os 30.000 registros oficiais do dataset Default of Credit Card Clients.

Entre as redes PyTorch avaliadas, Ativação tanh obteve a maior AP média de validação (0,543 ± 0,011). O XGBoost alcançou 0,543 ± 0,009 e permaneceu como padrão entre os três modelos integrados à aplicação. As diferenças pequenas entre os melhores candidatos não demonstram superioridade geral de um algoritmo.

A calibração selecionada pelo Brier médio de validação foi: regressão logística, isotonic; XGBoost, none; MLP scikit-learn, sigmoid. Os resultados de referência são complementares: o conjunto já havia sido consultado na etapa anterior e não é apresentado como teste inédito.

Palavras-chave: inadimplência; classificação binária; redes neurais; XGBoost; calibração de probabilidades.

1. Problema e perguntas de pesquisa

O objetivo é estimar se um cliente deixará de pagar no mês seguinte a partir do limite, perfil e histórico de seis meses. Como cerca de 22,1% dos registros pertencem à classe inadimplente, acurácia isolada é insuficiente.

P1: uma MLP supera kNN e classificadores lineares? P2: como largura, profundidade e ativação afetam o desempenho e a convergência? P3: quais efeitos são observados com L2, dropout, batch normalization e balanceamento? P4: como normalização, one-hot e inicialização mudam os resultados?

A regressão logística é o modelo de regressão apropriado ao alvo binário. XGBoost e random forest são referências adicionais para dados tabulares. kNN é um método supervisionado baseado em instâncias; sua etapa de ajuste armazena os exemplos, e não aprende uma parametrização como a rede neural.

2. Dados, limpeza e partições

A base reúne 30.000 clientes de um banco de Taiwan em 2005, com 6.636 inadimplentes, 23 atributos explicativos e um alvo binário. O ID é excluído dos modelos. A cópia incluída preserva a planilha oficial; origem e hashes estão em data/source.json. Licença: CC BY 4.0.

As categorias educação 0/5/6 são reunidas em 4; estado civil 0 é reunido em 3. Não há imputação automática nem geração de dados sintéticos. Números ausentes ou infinitos, categorias inválidas e pagamentos negativos são rejeitados. Faturas negativas são aceitas porque podem representar crédito.

Há 56 registros que repetem um perfil de atributos. Perfis idênticos são agrupados, inclusive quando os alvos divergem. Grupos são estratificados pelo maior alvo e nunca atravessam partições.

A referência de 4.504 registros é a mesma do primeiro desenvolvimento (semente 42). Nas novas execuções, ela é excluída de todas as partições de desenvolvimento. O restante é dividido em ajuste (65%), parada antecipada (10%), calibração (10%) e validação (15%). São frações do desenvolvimento, não da base total. A tabela mostra a realização da semente 42.

Partição	Registros	Taxa inadimplente
fit	16564	0,221
stop	2552	0,221
calibration	2549	0,221

Partição	Registros	Taxa inadimplente
validation	3831	0,221
Referência já consultada	4504	0,221

3. Protocolo e controle de vazamento

As sementes são 7, 21, 42, 84 e 123. Cada uma muda as partições de desenvolvimento e a aleatoriedade do treinamento. As 28 configurações usam as mesmas partições em cada semente, permitindo comparações pareadas. São cinco repetições de holdout, e não validação cruzada de cinco folds.

O scaler e o encoder são ajustados somente na partição fit. As redes PyTorch usam stop para parada antecipada. A MLP scikit-learn usa sua subdivisão interna de 15% de fit; portanto seu número efetivo de exemplos para gradiente difere do das redes PyTorch. Os calibradores usam somente calibration. A escolha dos métodos e dos limiares usa somente validation.

O protocolo foi registrado em results/research/protocol.json antes dos ajustes. Modelo da aplicação: maior AP média de validação entre regressão logística, XGBoost e MLP scikit-learn. Melhor configuração neural: maior AP média de validação entre as 18 redes PyTorch. Calibrador: menor Brier médio de validação entre none, sigmoid e isotonic. Limiar: F1 máximo na validação de cada execução.

As escolhas foram registradas antes da avaliação complementar de referência. O fato de a referência já ter sido consultada anteriormente impede chamá-la de teste inédito. A seleção de muitas configurações também pode produzir otimismo nas métricas de validação. Não há validação externa ou temporal.

4. Métricas e incerteza

A métrica principal de ordenação é average precision (AP), calculada pela soma dos incrementos de recall ponderados pela precisão. Ela não é idêntica à área trapezoidal da curva PR. Também são apresentados AUC-ROC, precisão, recall, F1, matriz de confusão, Brier score e log loss.

AP e AUC medem ordenação; Brier e log loss avaliam probabilidades. F1 e recall dependem do limiar. Os limiares são escolhidos na validação, antes de aplicar a regra à referência. A API usa o limiar exato, enquanto o controle visual arredonda para 0,1 ponto percentual.

Médias e desvios entre cinco sementes descrevem a variabilidade do procedimento. Os intervalos t de 95% e as diferenças pareadas estão nos CSVs; como as partições se sobrepõem, esses intervalos são descritivos e não sustentam testes de significância com observações independentes.

Na referência da semente 42, intervalos percentis de 95% usam 1.000 reamostragens de perfis de atributos, mantendo juntas as linhas de um mesmo perfil. São condicionais ao modelo ajustado: não incluem toda a incerteza de treinamento, seleção ou transferência para outra população.

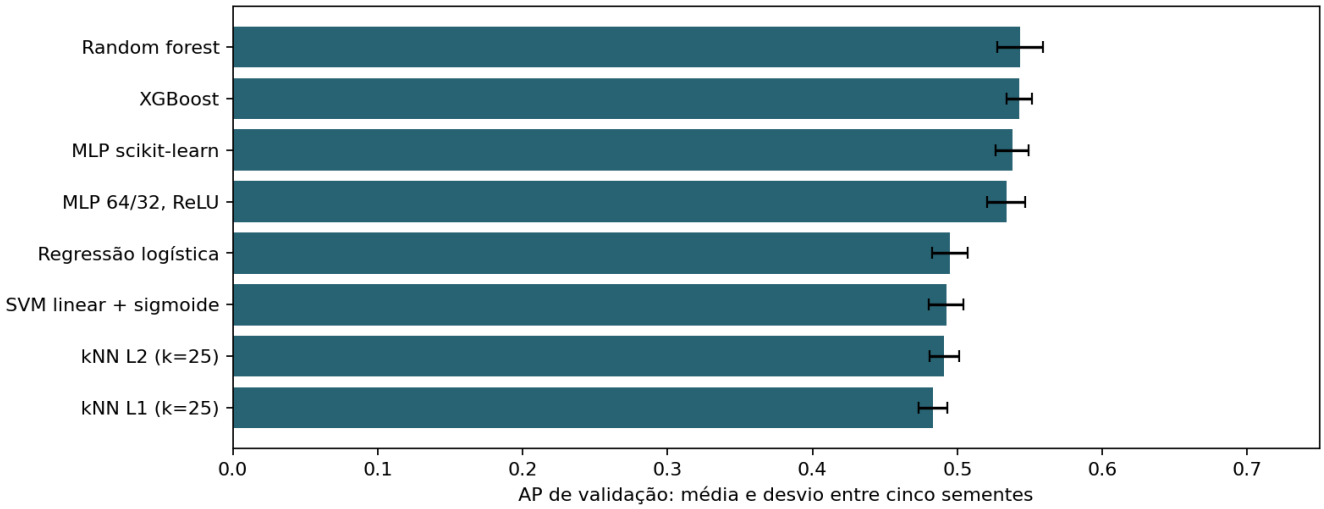
5. P1 — comparação de modelos

Os baselines usam regressão logística com C=1; SVM linear com C=1 e calibração sigmoide na partição de calibração; kNN com k=25 nas distâncias L1 e L2; random forest com 250 árvores, profundidade máxima 10 e mínimo de 10 exemplos por folha; e XGBoost com 350 árvores, profundidade 3 e learning rate 0,04. Os parâmetros completos constam do código e dos arquivos JSON.

A melhor MLP observada alcançou AP média de 0,543, frente a 0,495 da regressão, 0,483 do kNN L1 e 0,491 do kNN L2. Nesse protocolo, as redes superaram esses baselines pela AP média. Isso não implica que redes sejam sempre superiores.

Random forest (0,543), XGBoost (0,543) e a melhor MLP (0,543) ficaram próximos. O XGBoost é o padrão da aplicação por liderar o subconjunto dos três modelos nela integrados; não foi declarado vencedor de todos os 28 candidatos.

Modelo	AP média ± DP	ROC média	F1 médio	Recall médio
Regressão logística	0,495 ± 0,012	0,724	0,511	0,510
SVM linear + sigmoide	0,492 ± 0,012	0,720	0,511	0,497
kNN L1 (k=25)	0,483 ± 0,010	0,739	0,495	0,520
kNN L2 (k=25)	0,491 ± 0,010	0,742	0,507	0,537
Random forest	0,543 ± 0,016	0,773	0,541	0,562
XGBoost	0,543 ± 0,009	0,774	0,544	0,544
MLP scikit-learn	0,538 ± 0,011	0,768	0,536	0,572
MLP 64/32, ReLU	0,534 ± 0,013	0,769	0,535	0,557
Ativação tanh	0,543 ± 0,011	0,770	0,535	0,563



Resultados de validação; barras representam média e desvio entre sementes.

6. P2 — arquitetura, ativação e convergência

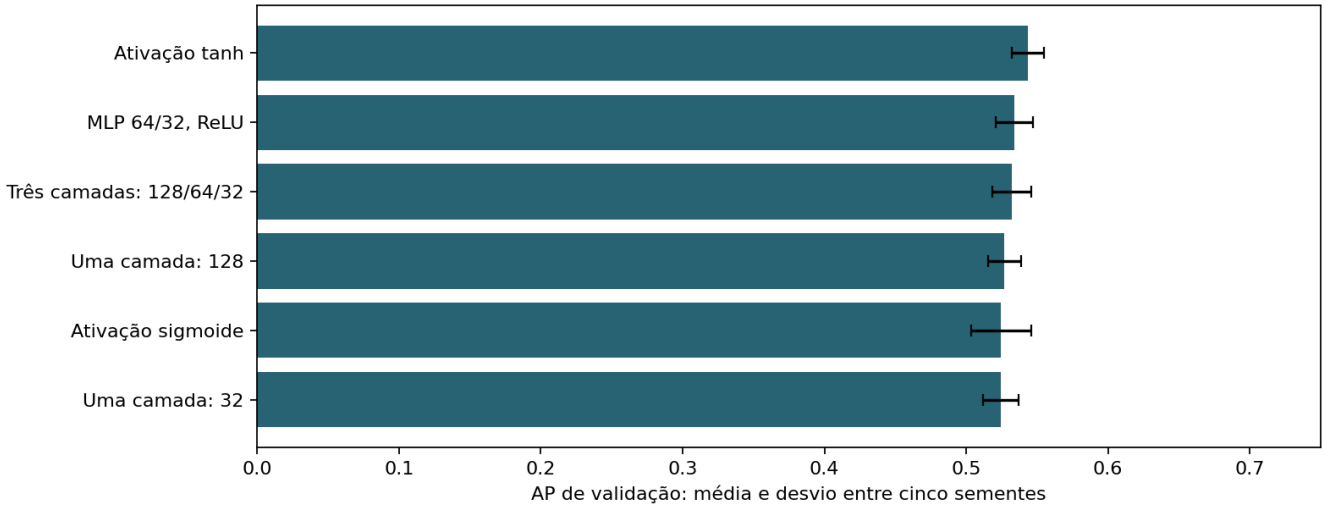
A configuração de controle tem camadas 64/32 e ReLU. Foram comparadas uma camada com 32 ou 128 neurônios, três camadas 128/64/32, tanh e sigmoide mantendo a arquitetura 64/32 nas mudanças de ativação. As demais condições do controle são preservadas.

As redes usam Adam, learning rate 0,001, lotes de até 512 exemplos e até 80 épocas. A parada antecipada tem paciência 10 e melhoria mínima 0,0001 na BCE não ponderada de stop. O melhor estado é restaurado. Todos os vieses iniciais são zero; o gradiente é limitado à norma 5.

Tanh foi a ativação com maior AP média entre as redes testadas (0,543). Aumentar a profundidade para três camadas não elevou a AP média sobre a rede 64/32 ReLU nesse desenho. A sigmoide exigiu em média 67,4 épocas até seu melhor estado, contra 25,6 do controle.

O gap informado é BCE de stop menos BCE de fit, medido no melhor estado; valores positivos indicam perda maior fora do ajuste. Ele não é, isoladamente, uma prova de overfitting nem resume toda a dinâmica das curvas.

Configuração	AP média ± DP	Melhor época média	Gap BCE médio
MLP 64/32, ReLU	0,534 ± 0,013	25,6	0,015
Uma camada: 32	0,524 ± 0,013	63,2	0,011
Uma camada: 128	0,527 ± 0,012	33,4	0,013
Três camadas: 128/64/32	0,532 ± 0,014	14,0	0,015
Ativação tanh	0,543 ± 0,011	43,2	0,011
Ativação sigmoide	0,525 ± 0,021	67,4	0,005



7. P3 — regularização e balanceamento

L2 é implementado por weight_decay=0,001 no Adam; dropout usa probabilidade 0,30; batch normalization é aplicada após as camadas lineares ocultas. Há ablações individuais e uma combinação das três técnicas. O peso positivo na BCE é a razão entre negativos e positivos de fit. A sobreamostragem aleatória iguala as classes usando apenas exemplos de fit.

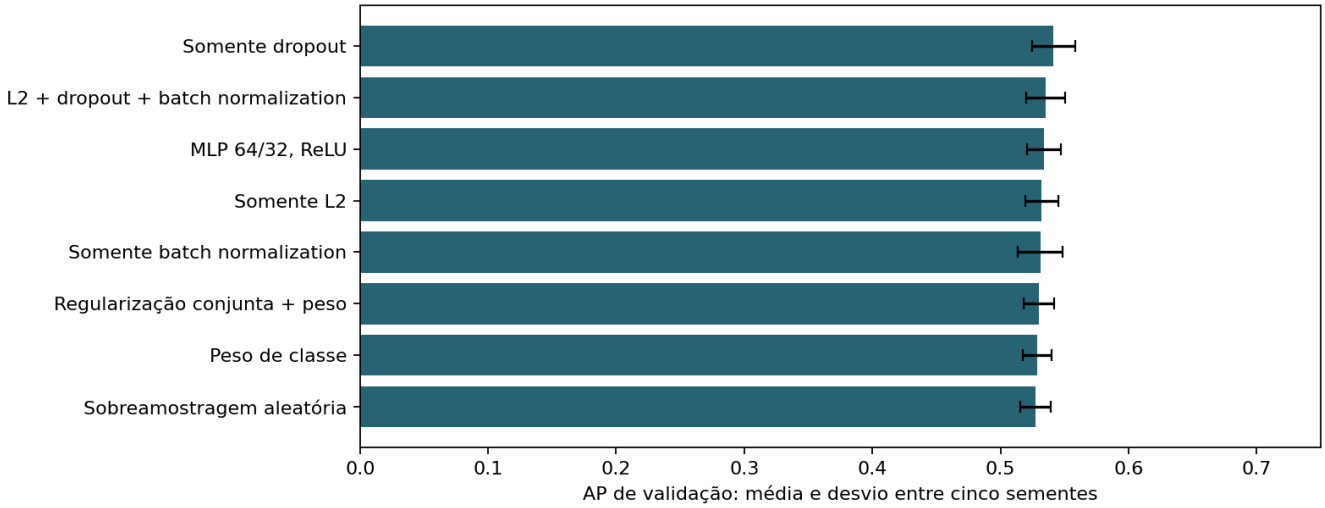
Dropout isolado teve AP média 0,541, frente a 0,534 do controle. A combinação de L2, dropout e batch normalization alcançou 0,535. Portanto adicionar mais regularização não trouxe uma melhoria monotônica.

O recall médio foi 0,557 no controle, 0,556 com peso de classe e 0,571 com sobreamostragem. Como o limiar foi otimizado separadamente em cada validação, esses valores refletem o efeito conjunto do treinamento e da decisão, e não apenas dos pesos.

A sobreamostragem aumenta o número de exemplos e de atualizações por época; o custo computacional por época não é o mesmo do controle. Pesos e amostragem podem distorcer probabilidades sem calibração. Os tempos e os tamanhos de ajuste após amostragem estão registrados por execução.

Configuração	AP média ± DP	Recall médio	Gap BCE médio
MLP 64/32, ReLU	0,534 ± 0,013	0,557	0,015
Somente L2	0,532 ± 0,013	0,564	0,011
Somente dropout	0,541 ± 0,017	0,567	0,012
Somente batch normalization	0,531 ± 0,018	0,558	0,017

Configuração	AP média ± DP	Recall médio	Gap BCE médio
L2 + dropout + batch normalization	0,535 ± 0,015	0,570	0,013
Peso de classe	0,529 ± 0,011	0,556	0,013
Sobreamostragem aleatória	0,527 ± 0,012	0,571	0,025
Regularização conjunta + peso	0,530 ± 0,012	0,543	0,013



8. P4 — pré-processamento e inicialização

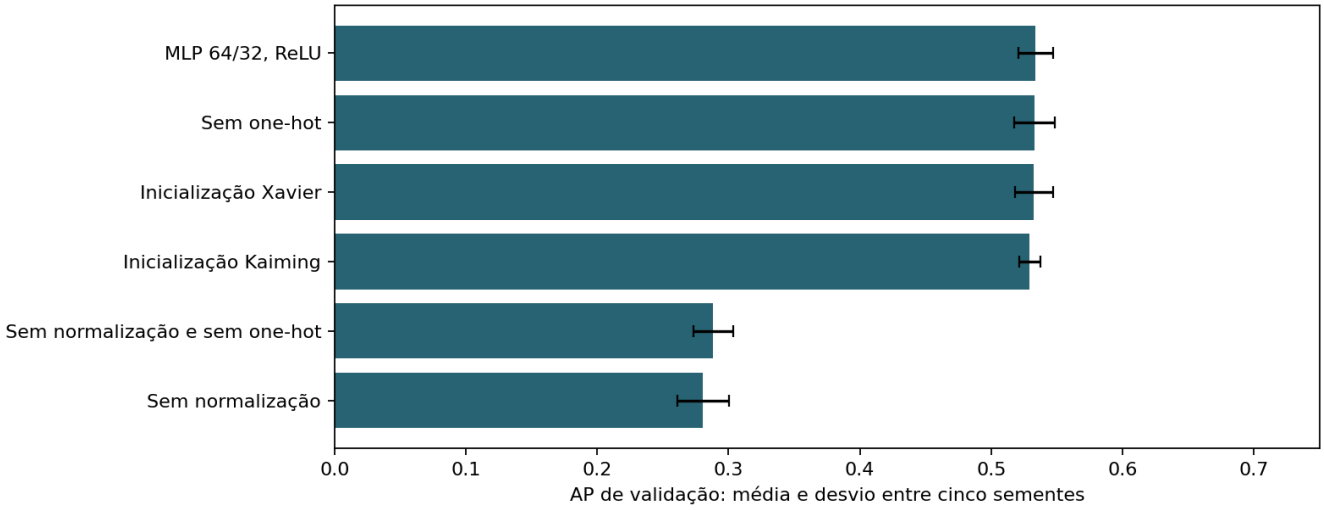
A normalização padroniza os atributos numéricos usando a média e o desvio de fit. One-hot é aplicado a sexo, escolaridade e estado civil. Sem one-hot, os códigos dessas categorias entram como valores numéricos. Sem normalização, os valores monetários permanecem em sua escala original.

A remoção da normalização reduziu a AP média de 0,534 para 0,281. Mantendo a normalização, a versão sem one-hot atingiu 0,533; a diferença para o controle foi pequena nesse conjunto de configurações.

As inicializações comparadas são a distribuição padrão das camadas lineares do PyTorch, Xavier uniforme e Kaiming normal. Os vieses permanecem zero em todos os casos. Xavier e Kaiming foram avaliadas com a rede ReLU de controle; seus resultados não justificam declarar uma inicialização universalmente melhor.

A comparação mantém a mesma taxa de aprendizado e o mesmo limite de épocas. A queda sem normalização descreve esse procedimento de otimização e não prova que qualquer rede sem normalização seja incapaz de aprender. As curvas da versão não normalizada usam escala symlog para permitir visualizar perdas muito maiores.

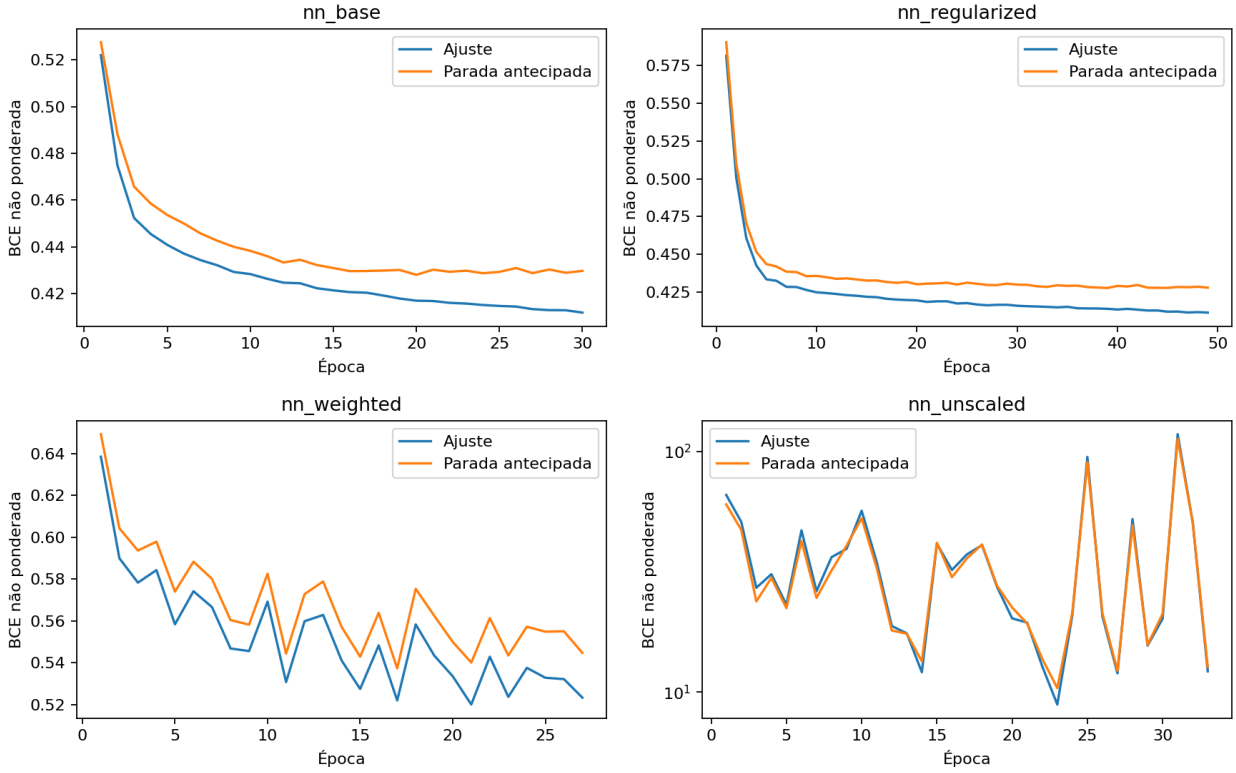
Configuração	AP média ± DP	ROC média	Melhor época média
MLP 64/32, ReLU	0,534 ± 0,013	0,769	25,6
Sem normalização	0,281 ± 0,020	0,618	21,0
Sem one-hot	0,533 ± 0,015	0,768	29,8
Sem normalização e sem one-hot	0,288 ± 0,015	0,628	18,6
Inicialização Xavier	0,532 ± 0,015	0,764	23,0
Inicialização Kaiming	0,529 ± 0,008	0,765	24,0



9. Curvas de aprendizagem

A figura mostra quatro configurações na semente 42: controle, regularização conjunta, peso de classe e ausência de normalização. As perdas são BCE não ponderada calculada em modo de avaliação, de modo que dropout fica desligado e batch normalization usa as estatísticas aprendidas. O objetivo usado durante o gradiente pode ser ponderado, mas a curva relatada usa a mesma definição de perda.

As curvas completas de todas as 90 redes estão em learning_curves.csv; melhores épocas e gaps estão em convergence.csv. Não são curvas calculadas sobre a referência.



10. Calibração de probabilidades

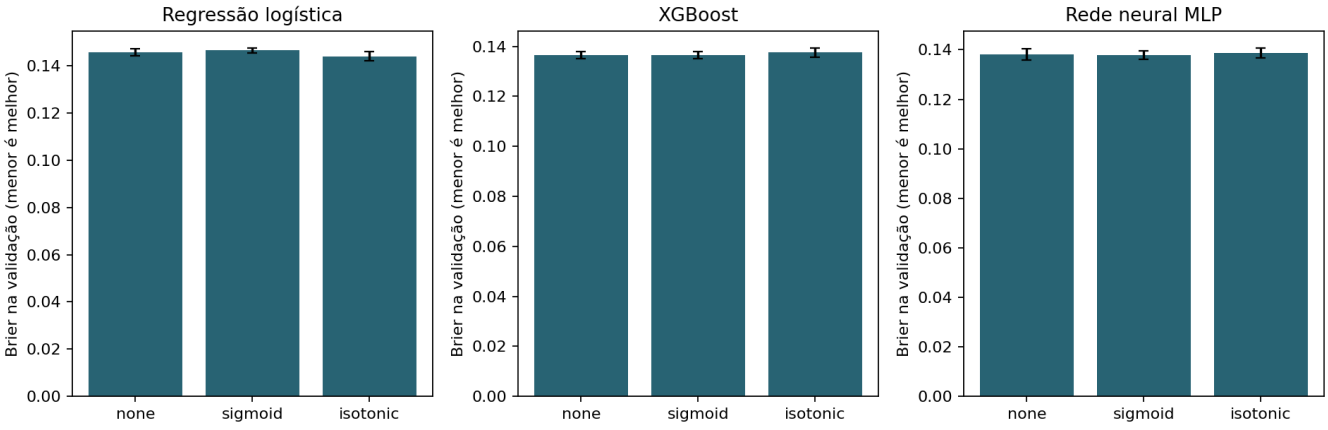
Foram comparados: none, que mantém a probabilidade original; sigmoid, regressão logística ajustada sobre o logit da probabilidade original com C=1.000.000; e isotonic, regressão isotônica monotônica. O calibrador recebe apenas as previsões e os alvos de calibration. Seu desempenho é comparado em validation.

A escolha usa o menor Brier médio nas cinco sementes, e não a aparência da curva ou a referência. Também são relatados log loss e ECE com dez intervalos uniformes. O diagrama de confiabilidade usa dez grupos por quantis; por isso seus agrupamentos diferem dos usados no ECE.

A regressão logística escolheu isotonic, a MLP scikit-learn escolheu sigmoid e o XGBoost manteve none. A isotônica reduziu o Brier médio da regressão, mas aumentou seu log loss médio: os critérios não são equivalentes. Probabilidades isotônicas nos extremos podem receber penalidade alta quando erram.

Os três modelos da aplicação foram atualizados com os métodos escolhidos. A melhor rede PyTorch permanece como artefato experimental separado; a MLP da aplicação continua sendo a implementação scikit-learn, agora calibrada.

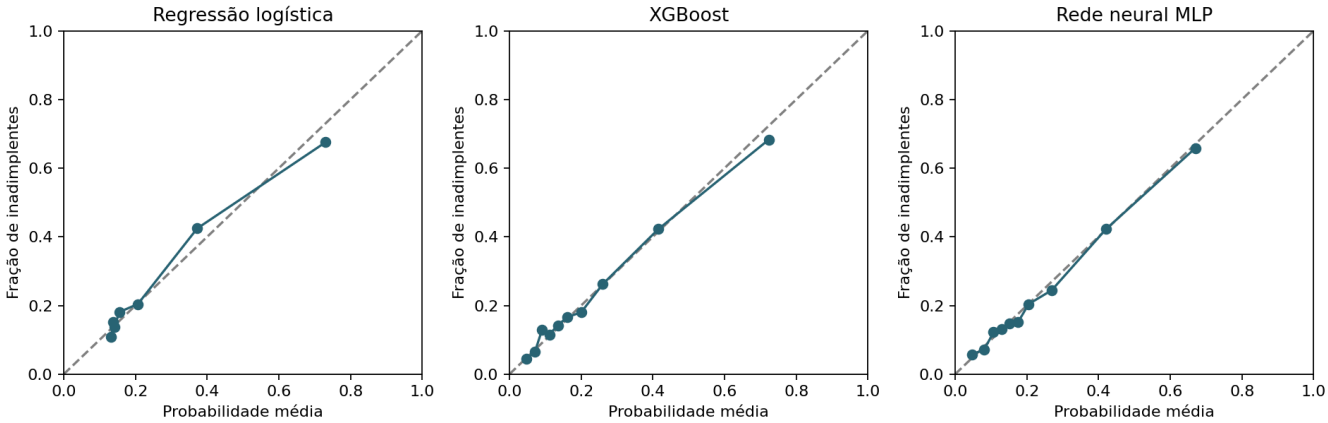
Modelo	Método	Brier médio ± DP	Log loss médio	ECE médio
Regressão logística	none	0,146 ± 0,002	0,467	0,045
Regressão logística	sigmoid	0,147 ± 0,001	0,467	0,049
Regressão logística	isotonic (escolhida)	0,144 ± 0,002	0,481	0,019
XGBoost	none (escolhida)	0,136 ± 0,001	0,434	0,014
XGBoost	sigmoid	0,137 ± 0,001	0,434	0,016
XGBoost	isotonic	0,138 ± 0,002	0,448	0,023
Rede neural MLP	none	0,138 ± 0,002	0,440	0,019
Rede neural MLP	sigmoid (escolhida)	0,138 ± 0,002	0,438	0,015
Rede neural MLP	isotonic	0,139 ± 0,002	0,450	0,017



11. Confiabilidade na referência já consultada

Os pontos mostram a fração observada de inadimplentes contra a probabilidade média de cada grupo, para os modelos finais da semente 42. A diagonal representa coincidência entre as duas medidas. Oscilações, sobretudo em grupos pequenos e extremos, não devem ser interpretadas como estabilidade fora desta base.

Esses diagramas são descritivos e não foram usados para refazer a escolha dos calibradores. A base de referência já havia sido observada em uma etapa anterior.



12. Avaliação complementar de referência

Após salvar as escolhas, os modelos foram aplicados aos mesmos 4.504 registros da referência original. A tabela mostra a realização da semente 42. AP, AUC e limiares podem diferir do primeiro desenvolvimento, pois agora parte do desenvolvimento é reservada para parada antecipada e calibração.

Os intervalos abaixo são bootstrap por perfil, condicionais ao modelo ajustado. A avaliação inclui os baselines de P1 e a melhor rede selecionada na validação. Não foi feita nova seleção usando esses resultados.

O XGBoost final teve AP 0,529, AUC-ROC 0,768 e recall 0,512. Sua matriz registra 3.075 adimplentes corretamente identificados, 434 falsos positivos, 486 inadimplentes não detectados e 509 verdadeiros positivos. O desempenho continua deixando uma parcela relevante de inadimplentes sem identificação.

Modelo	AP	IC 95% AP	ROC	F1	Recall
Regressão logística	0,468	0,434–0,502	0,712	0,492	0,452
XGBoost	0,529	0,496–0,566	0,768	0,525	0,512
Rede neural MLP	0,517	0,483–0,552	0,756	0,511	0,578
kNN L1	0,479	0,444–0,513	0,737	0,486	0,480
kNN L2	0,475	0,441–0,508	0,730	0,490	0,490
SVM linear	0,485	0,451–0,522	0,708	0,481	0,425
Random forest	0,534	0,500–0,569	0,764	0,526	0,555
MLP PyTorch: tanh	0,524	0,490–0,558	0,758	0,521	0,588

13. Atributos sensíveis e diferenças por grupo

Foram repetidos os três modelos da aplicação removendo, em conjunto, sexo, idade e estado civil do pré-processamento. As comparações usam as mesmas partições e os mesmos hiperparâmetros; a tabela mostra a AP média de validação antes de calibração adicional.

Uma alteração pequena de AP após excluir atributos sensíveis não comprova justiça. Outras variáveis podem funcionar como proxies. Também não se pode concluir causalidade ou adequação jurídica a partir dessas métricas.

A análise descritiva por sexo, estado civil e faixa etária apresenta tamanho do grupo, prevalência, recall e taxa de falsos positivos na referência. Ela não define um critério normativo de equidade nem inclui uma

validação independente de discriminação.

Modelo	AP completa	AP sem sensíveis	Diferença
Regressão logística	0,495	0,494	-0,001
XGBoost	0,543	0,540	-0,003
Rede neural MLP	0,538	0,519	-0,019

13.1. Grupos no modelo padrão

Codificações: SEX 1 masculino, 2 feminino; MARRIAGE 1 casado, 2 solteiro, 3 outro. AGE_GROUP indica faixas de idade. As métricas usam o limiar validado do XGBoost. Grupos pequenos têm incerteza maior; os valores abaixo não recebem interpretação causal.

Atributo / grupo	n	Prevalência	Recall	Falsos positivos
SEX / 1	1761	0,229	0,505	0,150
SEX / 2	2743	0,215	0,516	0,107
MARRIAGE / 1	2136	0,228	0,539	0,138
MARRIAGE / 2	2322	0,214	0,485	0,111
MARRIAGE / 3	46	0,261	0,500	0,088
AGE_GROUP / 18–29	1421	0,222	0,521	0,127
AGE_GROUP / 30–44	2304	0,215	0,486	0,117
AGE_GROUP / 45–59	725	0,230	0,557	0,136
AGE_GROUP / 60–100	54	0,315	0,647	0,162

14. Cenários de custo e limiares

Foi realizada uma análise de sensibilidade ilustrativa: custo de falso positivo fixado em 1 e custo de falso negativo em 1, 2, 5 ou 10. Para cada cenário, o limiar que minimiza o custo é escolhido na validação e aplicado à referência.

Os custos por mil clientes são unidades hipotéticas, não reais, NT$ ou estimativas de perda financeira. O dataset não traz custos de concessão, cobrança e recuperação suficientes para definir uma política comercial. O limiar padrão do aplicativo continua sendo o de F1 validado; estes cenários são uma análise separada.

Custo FN / FP	Limiar validação	FN referência	FP referência	Custo / mil
1 / 1	0,396	572	261	184,9
2 / 1	0,299	486	434	312,2
5 / 1	0,192	327	981	580,8
10 / 1	0,083	55	2610	701,6

15. Integração, testes e reprodutibilidade

A aplicação oferece regressão logística, XGBoost e MLP scikit-learn com os calibradores selecionados. Os fatores são sensibilidade ao substituir grupos pela mediana/moda de fit: não são explicações causais, SHAP nem parcelas aditivas. Indisponibilidade do artefato retorna HTTP 503; não há regra manual substituta.

O código inclui testes de entradas inválidas, calibração sem novo ajuste do modelo base, equivalência entre API e artefato, partições sem vazamento, índices reproduzíveis, treino neural determinístico em CPU e falhas de carregamento. O navegador é verificado em desktop e celular, com troca de modelo, limiar, rede indisponível e cancelamento de resposta desatualizada.

Comandos: python main.py --serve para a aplicação; python research.py --integrate --resume para repetir ou retomar a pesquisa; python build_report.py para reconstruir os PDFs; python -m pytest -q para os testes. Dependências de pesquisa e de geração dos documentos são opcionais ao uso da aplicação e estão separadas das dependências de inferência.

Os artefatos incluem protocolo, resultados por execução, médias e desvios, diferenças pareadas, predições de validação e referência, curvas por época, configurações, pesos da melhor rede e checksums. As versões do ambiente e o hash dos dados permitem verificar a origem dos resultados.

16. Limitações e conclusões

P1: as redes testadas superaram kNN e classificadores lineares pela AP média observada; as melhores redes e os modelos de árvores ficaram próximos. P2: tanh teve o melhor resultado entre as ativações estudadas; profundidade maior não assegurou melhora. P3: dropout ajudou nesse desenho, enquanto a combinação de técnicas e o balanceamento não trouxeram ganhos uniformes. P4: a normalização teve efeito muito maior do que retirar one-hot ou trocar a inicialização nas condições testadas.

Calibrar não é necessariamente melhorar todas as métricas. Os métodos finais foram escolhidos pelo Brier de validação, preservando a opção de não ajustar o XGBoost. A escolha por Brier pode divergir de log loss e de métricas de ordenação.

Os cinco resultados por configuração não são cinco amostras independentes da população. A busca é limitada a uma grade pequena e a uma taxa de aprendizado. Não houve busca exaustiva, teste externo recente ou validação temporal. O conjunto de referência já tinha sido consultado e seus intervalos são condicionais aos modelos.

A base de um banco de Taiwan em 2005 não representa automaticamente crédito brasileiro atual. Para implantação operacional seriam necessários dados recentes e autorizados, custos reais, análise de governança e validação de equidade. Essas são limitações de aplicação e generalização, e não resultados demonstrados pelo experimento.

Referências

YEH, I-Cheng; LIEN, Che-hui. Default of Credit Card Clients. UCI Machine Learning Repository, 2009. DOI: 10.24432/C55S3H. Licença CC BY 4.0.

YEH, I-Cheng; LIEN, Che-hui. The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. Expert Systems with Applications, v. 36, n. 2, 2009.

CHEN, Tianqi; GUESTRIN, Carlos. XGBoost: A Scalable Tree Boosting System. KDD, 2016. DOI: 10.1145/2939672.2939785.

SRIVASTAVA, Nitish et al. Dropout: A Simple Way to Prevent Neural Networks from Overfitting. Journal of Machine Learning Research, v. 15, 2014.

IOFFE, Sergey; SZEGEDY, Christian. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. ICML, 2015.

GUO, Chuan et al. On Calibration of Modern Neural Networks. ICML, 2017.

KINGMA, Diederik P.; BA, Jimmy. Adam: A Method for Stochastic Optimization. ICLR, 2015.

PASZKE, Adam et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library. NeurIPS, 2019.

Apêndice — versões e leitura dos arquivos

Versões: torch 2.10.0+cpu; scikit-learn 1.8.0; numpy 2.3.5; pandas 2.2.3; xgboost 3.4.1; scipy 1.17.0; Python 3.12.14.

experiments.csv: 140 ajustes e métricas de validação. summary.csv: média, desvio e intervalos descritivos. paired_differences.csv: diferenças contra a rede de controle. calibration.csv: 45 avaliações de métodos de calibração. calibration_reference.csv: avaliação complementar dos nove pares modelo/método. final_evaluation.json: escolhas, métricas e intervalos bootstrap. cost_scenarios.csv: cenários de custo. split_seed_*.npz: índices completos de cada semente.

O protocolo registrado usa máximo de 80 épocas, paciência 10 e sementes 7/21/42/84/123. Os 140 ajustes incluem 7 baselines, 18 configurações PyTorch e 3 ablações de atributos sensíveis por semente. As 45 avaliações de calibração usam predições desses modelos, sem novo treinamento dos classificadores.

Os documentos originais recebidos estão em docs/originais. Este relatório descreve experimentos executados e não reproduz como fatos as hipóteses das propostas anteriores.