# Síntese da pesquisa de inadimplência

## Da proposta aos experimentos executados

Estudo executado com dados oficiais da UCI · cinco sementes · código e resultados reproduzíveis

Autores informados no repositório: Athos Andre, Lucas Brasileiro, Guilherme Uchoa, Matheus Albuquerque e Dhigor Padilha.

Base: Taiwan, abril a setembro de 2005. O conjunto de referência já foi consultado em etapa anterior.

## Resumo

Este estudo compara classificadores de inadimplência de cartão de crédito e investiga o efeito de arquitetura, ativação, regularização, balanceamento e preparação dos dados em redes neurais. Foram executados 140 ajustes: 28 configurações em cinco sementes, usando os 30.000 registros oficiais do dataset Default of Credit Card Clients.

Entre as redes PyTorch avaliadas, Ativação tanh obteve a maior AP média de validação (0,543 ± 0,011). O XGBoost alcançou 0,543 ± 0,009 e permaneceu como padrão entre os três modelos integrados à aplicação. As diferenças pequenas entre os melhores candidatos não demonstram superioridade geral de um algoritmo.

## 2. Dados, limpeza e partições

A base reúne 30.000 clientes de um banco de Taiwan em 2005, com 6.636 inadimplentes, 23 atributos explicativos e um alvo binário. O ID é excluído dos modelos. A cópia incluída preserva a planilha oficial; origem e hashes estão em data/source.json. Licença: CC BY 4.0.

As categorias educação 0/5/6 são reunidas em 4; estado civil 0 é reunido em 3. Não há imputação automática nem geração de dados sintéticos. Números ausentes ou infinitos, categorias inválidas e pagamentos negativos são rejeitados. Faturas negativas são aceitas porque podem representar crédito.

| Partição | Registros | Taxa inadimplente |
|---|---|---|
| fit | 16564 | 0,221 |
| stop | 2552 | 0,221 |
| calibration | 2549 | 0,221 |
| validation | 3831 | 0,221 |
| Referência já consultada | 4504 | 0,221 |

## 3. Protocolo e controle de vazamento

As sementes são 7, 21, 42, 84 e 123. Cada uma muda as partições de desenvolvimento e a aleatoriedade do treinamento. As 28 configurações usam as mesmas partições em cada semente, permitindo comparações pareadas. São cinco repetições de holdout, e não validação cruzada de cinco folds.

O scaler e o encoder são ajustados somente na partição fit. As redes PyTorch usam stop para parada antecipada. A MLP scikit-learn usa sua subdivisão interna de 15% de fit; portanto seu número efetivo de exemplos para gradiente difere do das redes PyTorch. Os calibradores usam somente calibration. A escolha dos métodos e dos limiares usa somente validation.

## 5. P1 — comparação de modelos

Os baselines usam regressão logística com C=1; SVM linear com C=1 e calibração sigmoide na partição de calibração; kNN com k=25 nas distâncias L1 e L2; random forest com 250 árvores, profundidade máxima 10 e mínimo de 10 exemplos por folha; e XGBoost com 350 árvores, profundidade 3 e learning rate 0,04. Os parâmetros completos constam do código e dos arquivos JSON.

A melhor MLP observada alcançou AP média de 0,543, frente a 0,495 da regressão, 0,483 do kNN L1 e 0,491 do kNN L2. Nesse protocolo, as redes superaram esses baselines pela AP média. Isso não implica que redes sejam sempre superiores.

| Modelo | AP média ± DP | ROC média | F1 médio | Recall médio |
|---|---|---|---|---|
| Regressão logística | 0,495 ± 0,012 | 0,724 | 0,511 | 0,510 |
| SVM linear + sigmoide | 0,492 ± 0,012 | 0,720 | 0,511 | 0,497 |
| kNN L1 (k=25) | 0,483 ± 0,010 | 0,739 | 0,495 | 0,520 |
| kNN L2 (k=25) | 0,491 ± 0,010 | 0,742 | 0,507 | 0,537 |
| Random forest | 0,543 ± 0,016 | 0,773 | 0,541 | 0,562 |
| XGBoost | 0,543 ± 0,009 | 0,774 | 0,544 | 0,544 |
| MLP scikit-learn | 0,538 ± 0,011 | 0,768 | 0,536 | 0,572 |
| MLP 64/32, ReLU | 0,534 ± 0,013 | 0,769 | 0,535 | 0,557 |
| Ativação tanh | 0,543 ± 0,011 | 0,770 | 0,535 | 0,563 |

## 10. Calibração de probabilidades

Foram comparados: none, que mantém a probabilidade original; sigmoid, regressão logística ajustada sobre o logit da probabilidade original com C=1.000.000; e isotonic, regressão isotônica monotônica. O calibrador recebe apenas as previsões e os alvos de calibration. Seu desempenho é comparado em validation.

A escolha usa o menor Brier médio nas cinco sementes, e não a aparência da curva ou a referência. Também são relatados log loss e ECE com dez intervalos uniformes. O diagrama de confiabilidade usa dez grupos por quantis; por isso seus agrupamentos diferem dos usados no ECE.

| Modelo | Método | Brier médio ± DP | Log loss médio | ECE médio |
|---|---|---|---|---|
| Regressão logística | none | 0,146 ± 0,002 | 0,467 | 0,045 |
| Regressão logística | sigmoid | 0,147 ± 0,001 | 0,467 | 0,049 |
| Regressão logística | isotonic (escolhida) | 0,144 ± 0,002 | 0,481 | 0,019 |
| XGBoost | none (escolhida) | 0,136 ± 0,001 | 0,434 | 0,014 |
| XGBoost | sigmoid | 0,137 ± 0,001 | 0,434 | 0,016 |
| XGBoost | isotonic | 0,138 ± 0,002 | 0,448 | 0,023 |
| Rede neural MLP | none | 0,138 ± 0,002 | 0,440 | 0,019 |
| Rede neural MLP | sigmoid (escolhida) | 0,138 ± 0,002 | 0,438 | 0,015 |
| Rede neural MLP | isotonic | 0,139 ± 0,002 | 0,450 | 0,017 |

## 12. Avaliação complementar de referência

Após salvar as escolhas, os modelos foram aplicados aos mesmos 4.504 registros da referência original. A tabela mostra a realização da semente 42. AP, AUC e limiares podem diferir do primeiro desenvolvimento, pois agora parte do desenvolvimento é reservada para parada antecipada e calibração.

Os intervalos abaixo são bootstrap por perfil, condicionais ao modelo ajustado. A avaliação inclui os baselines de P1 e a melhor rede selecionada na validação. Não foi feita nova seleção usando esses resultados.

| Modelo | AP | IC 95% AP | ROC | F1 | Recall |
|---|---|---|---|---|---|
| Regressão logística | 0,468 | 0,434–0,502 | 0,712 | 0,492 | 0,452 |
| XGBoost | 0,529 | 0,496–0,566 | 0,768 | 0,525 | 0,512 |
| Rede neural MLP | 0,517 | 0,483–0,552 | 0,756 | 0,511 | 0,578 |
| kNN L1 | 0,479 | 0,444–0,513 | 0,737 | 0,486 | 0,480 |
| kNN L2 | 0,475 | 0,441–0,508 | 0,730 | 0,490 | 0,490 |
| SVM linear | 0,485 | 0,451–0,522 | 0,708 | 0,481 | 0,425 |
| Random forest | 0,534 | 0,500–0,569 | 0,764 | 0,526 | 0,555 |
| MLP PyTorch: tanh | 0,524 | 0,490–0,558 | 0,758 | 0,521 | 0,588 |

## 16. Limitações e conclusões

P1: as redes testadas superaram kNN e classificadores lineares pela AP média observada; as melhores redes e os modelos de árvores ficaram próximos. P2: tanh teve o melhor resultado entre as ativações estudadas; profundidade maior não assegurou melhora. P3: dropout ajudou nesse desenho, enquanto a combinação de técnicas e o balanceamento não trouxeram ganhos uniformes. P4: a normalização teve efeito muito maior do que retirar one-hot ou trocar a inicialização nas condições testadas.

Calibrar não é necessariamente melhorar todas as métricas. Os métodos finais foram escolhidos pelo Brier de validação, preservando a opção de não ajustar o XGBoost. A escolha por Brier pode divergir de log loss e de métricas de ordenação.